



Önálló laboratórium beszámoló

Távközlési és Mesterséges Intelligencia Tanszék

Készítette:	Birta Tamás
Neptun-kód:	R18PB6
Szakirány:	Mérnökinformatika
E-mail cím:	birtatamas2@gmail.com
Konzulens(ek):	Szmida Patrik Péter Toka László
E-mail címe(ik):	szmida.patrikpeter@edu.bme.hu toka.laszlo@vik.bme.hu

Téma címe:

Esport analitika (CS2 esport játék adatok elemzése)

Feladat

A féléves munka célja annak vizsgálata volt, hogy a Counter-Strike 2 mérkőzések gránáthasználatához kapcsolódó jellemzői mennyi többletinformációt adnak a körkimenetel becsléséhez. Ehhez egy gépi tanulási keretrendszer készült, amely játékalapokat alapján becsüli a terrorelhárító oldal körgyőzelmi valószínűségét. A round win probability modell így nem önálló végcélként, hanem elemzési eszközként szolgált a különböző jellemzőcsoportok, főként a gránátváltozók szerepének összehasonlítására.

Elsőként egy pillanatkép alapú, XGBoost-ra épülő alapmodell készült meccsszintű adatszétválasztással, teljesítményméréssel és nagy adathalmazra skálázható tanítási folyamattal. Ezt követően a gránátjellegű jellemzők hatását ablációs, összehasonlító és bizonytalansági vizsgálatok elemezték. A projekt végén egy időfüggő LSTM modell is készült, amely a gránáthasználat és más események körön belüli időbeli hatását vizsgálta a győzelmi valószínűség változásain keresztül.

1. A laboratóriumi munka környezetének ismertetése, a munka előzményei és kiindulási állapota

1.1 Bevezető

A mesterséges intelligencia és az adatvezérelt elemzés az elmúlt években a tudományos és ipari gyakorlat egyik legmeghatározóbb eszközrendszerévé vált. Az ilyen módszerek különösen azokban a feladatokban hasznosak, ahol nagy mennyiségű adatból kell mintázatokot feltárni, előrejelzéseket készíteni, vagy döntéstámogató következtetéseket levonni. Ennek következtében az adatelemzés és a gépi tanulás ma már nemcsak klasszikus informatikai vagy üzleti környezetben jelenik meg, hanem számos más alkalmazási területen is, többek között a sportanalitikában és az esporttal kapcsolatos vizsgálatokban.

1.2 Sportanalitika és Counter-Strike

A sportanalitika célja, hogy a mérkőzések során keletkező adatokból a csapatok, játékosok és szakmai döntéshozók számára értékes információt állítson elő. Ez jelentheti például egy adott helyzet kimenetelének becslését, egy játékos vagy csapat teljesítményének értékelését, vagy olyan összefüggések feltárását, amelyek emberi megfigyeléssel nehezebben lennének azonosíthatók. Az esport esetében ez a megközelítés különösen ígéretes, mivel a digitális játékok világában gyakran kifejezetten részletes, időben finoman felbontott állapotadatok állnak rendelkezésre.

Az önálló laboratóriumi munka a Counter-Strike 2 esportelemzésére fókuszál. A Counter-Strike 2 egy csapatalapú, körökre bontott, taktikai lövöldözős játék, amelyben két öt fős csapat versenyez egymással. A terrorista oldal célja jellemzően az egyik kijelölt bombalera kó hely elfoglalása és a bomba telepítése, míg a terrorelhárító oldal feladata ennek megakadályozása, illetve a már telepített bomba hatástalanítása. A körök kimenetelét egyszerre befolyásolja az élő játékosok száma, az életerő, a felszerelés, a pozíciós helyzet, az idő, valamint a gránáthasználat. Emiatt természetes elemzési kérdés, hogy egy adott pillanatban mennyire becsülhető meg a kör végső kimenetele, és hogy mely jellemzők hordozzák a legfontosabb információt ehhez.

1.3 Kapcsolódó szakirodalom

A Counter-Strike elemzéséhez kapcsolódó szakirodalomban több olyan munka is található, amely részletes játékállapotokból próbál játékos, csapatszintű vagy mérkőzéskimeneteli következtetéseket levonni. Xenopoulos és szerzőtársai Counter-Strike környezetben játékosakciók értékelésével foglalkoztak [1], egy másik munkájuk pedig a játékon belüli gazdasági döntések modellezését vizsgálta [2]. Ezek a munkák azt mutatják, hogy a játék részletes állapotleírása jól használható összetettebb analitikai és gépi tanulási feladatokhoz.

1.4 Célkitűzés

A dolgozat célja Counter-Strike 2 mérkőzésadatokra épülő gépi tanulási módszerek alkalmazása a körkimenetel becslésének vizsgálatára, különös tekintettel a gránáthasználatához kapcsolódó jellemzők szerepére. A központi kérdés annak elemzése, hogy ezek a változók milyen mértékben járulnak hozzá a terrorelhárító oldal környezeti valószínűségének becsléséhez, és mennyiben hordoznak olyan többletinformációt, amely a modellek számára hasznosítható.

A célkitűzés megvalósításához a dolgozat két model családra épül. Az egyik az XGBoost, amely táblázatos adatokon erős teljesítményt nyújtó döntési faegyüttes, ezért természetes választás olyan feladatokban, ahol a bemenet gondosan előállított numerikus jellemzőkből áll [3]. A másik az LSTM, amely időbeli összefüggések modellezésére alkalmas rekurzív neurális hálózat, ezért akkor lehet hasznos, ha nemcsak az aktuális állapot, hanem a közeli múlt eseménysora is fontos információt hordoz [4].

1.2 A munka állapota, készültségi foka a félév elején

A félév elején a téma és az alapvető kutatási irány már adott volt, azonban a teljes feldolgozási és modellezési folyamat még nem állt készen. Rendelkezésre álltak a feldolgozható mérközésadatok, valamint a probléma szakmai kerete, de hiányzott az egységes adat-előállítási lánc, a megbízható tanító-, érvényesítő- és tesztalalmaz-képzés, valamint a stabilan futtatható modellezési környezet.

2. Az elvégzett munka és eredmények ismertetése

2.1 Adathalmaz-létrehozás és adatelőkészítés

2.1.1 Az adathalmaz forrása és szerkezete

A projektben felhasznált adathalmaz professzionális Counter-Strike 2 mérkőzések demófájljaiból származik. A demófájl a játék által rögzített visszajátszásállomány, amelyből a mérkőzés eseményei és játékállapotai utólag feldolgozható formában visszanyerhetők. A teljes feldolgozott állomány összesen 1540 demo fájl tartalmazott, amelyek több versenysorozat mérkőzéseit fedték le.

Az alapadatok előállítása AWPY-alapú feldolgozási folyamatban történt. A nyers demók 64 pillanatképfelvétel részletességgel álltak rendelkezésre, azonban a végső adathalmaz 32-es lépésközzel, vagyis másodpercenként két pillanatkép sűrűséggel készült el. Ennek megfelelően a végleges táblázat minden sora a mérkőzés egy adott félmásodperces időpillanatához tartozó játékállapotot ír le.

Ezekből a pillanatnyi állapotleírásokból jött létre a modell tanításához felhasznált strukturált tanítóadathalmaz. Az így kapott adatok többféle információt tartalmaznak, többek között a kör aktuális állapotára, a két oldal erőforrásaira, térbeli helyzetére, a közelmúltbeli harci eseményekre, valamint a gránáthasználatra vonatkozó jellemzőket. Az AWPY-ból közvetlenül kinyerhető alapváltozók közé tartoztak például a játékosok koordinátái, életerejé, páncélzata, pénze, felszerelésértéke, készlete, aktuális fegyverei, mozgásállapota, illetve a helymegnevezésekhez és a bombaterületekhez kapcsolódó információk. Emellett rendelkezésre álltak a lövésekhez, sebzésekhez, gyilkosságokhoz, bombaeseményekhez, valamint a füst- és tűzobjektumokhoz kötődő eseménylisták is.

Erre az alaprétgre épülve készült el a modell tanítására használt tabuláris adathalmaz. A nyers állapotváltozók mellett több saját számított jellemző is bekerült a reprezentációba. Ilyenek voltak például a két oldal élő játékosainak számát, összesített életerejét, páncélzatát, pénzügyi helyzetét és felszerelésértékét összevető különbségi változók. Készültek továbbá olyan jellemzők is, amelyek a két csapat gránátkészletének eltérését, a közelmúltbeli sebzés- és öléskülönbséget, valamint a két oldal térbeli elrendeződését és egymáshoz viszonyított távolságát írták le. A gránáthasználat részletesebb modellezéséhez külön területi jellemzők is létrejöttek: ezek rögzítették az elmúlt néhány másodperc gránáteseményeit, az aktív füst- és tűzobjektumok számát, valamint azt is, hogy az egyes bombakerakóhelyek közelében melyik oldal milyen mennyiségű utility-t használt.

Ennek eredményeként egy rekord egyszerre tartalmazta:

- a kör és az idő aktuális állapotát,
- a két oldal élő játékosaira, életerejére és felszerelésére vonatkozó összesítéseket,
- gazdasági és felszerelésérték-jellegű mutatókat,
- pozíciós és területfoglalási jellemzőket,
- az elmúlt néhány másodperc harci eseményeit összegző változókat,
- a gránátkészlethez, az aktív smoke- és inferno-objektumokhoz, valamint a friss utility-használathoz kapcsolódó oszlopokat,
- továbbá rendezett játékos szintű részletező változókat is.

A végleges reprezentáció teljes utility-változatban 500-nál több bemeneti jellemzőt tartalmazott; a később használt teljes modell 531 oszlopból tanult. A célváltozó minden rekord esetében bináris volt: a `ct_win` címke 1 értéket vett fel, ha az adott kör végül terrorelhárító

oldali győzelemmel zárult, és 0 értéket, ha nem.

Az adatfeldolgozás meccsenként külön történt. Minden demófájl önállóan került feldolgozásra, az így előálló pillanatkép szintű DataFrame pedig külön CSV állományként lett elmentve.

2.1.2 Adatelőkészítés és reprezentáció

Az adathalmaz kialakításának célja az volt, hogy a mérkőzések pillanatnyi állapotát minél részletesebben, ugyanakkor gépi tanulási módszerekkel is feldolgozható formában lehessen leírni. Ennek megfelelően a létrehozott tabuláris adathalmaz nem egyetlen szűken kiválasztott jellemzőhalmazra épült, hanem többféle, eltérő jellegű változót is tartalmazott. A reprezentációba ezért egyszerre kerültek be általános állapotjellemzők, gazdasági és felszerelési mutatók, pozíciós információk, harci eseményekhez kapcsolódó változók, valamint a gránáthasználatot leíró oszlopok is.

A jellemzők egy része aggregált, numerikus formában írta le az adott pillanatot. Ilyen volt például az élő játékosok száma, az összesített életerő, a páncélzat, a pénz, a felszerelésérték, az elmúlt néhány másodperc sebzésadata, vagy a gránátkészlethez kapcsolódó információ. Emellett olyan részletesebb változók is bekerültek az adathalmazba, amelyek a pozíciókhoz, a fegyverzethez vagy az egyes játékosok állapotához kapcsolódtak.

Ez a megközelítés lehetővé tette, hogy a későbbi feltáró elemzés és modellezés során kiderüljön, mely jellemzőcsoportok hordoznak valóban hasznos információt a körkimenetel becsléséhez, és mely változók bizonyulnak inkább zajosnak vagy túlzottan specifikusnak.

2.2 Feltáró adatelemzés


A modellezést feltáró adatelemzés előzte meg. Ennek célja az volt, hogy az adathalmaz szerkezete, fő eloszlásai és a körkimenet szempontjából legerősebb jelöltek még a modellezési szakasz előtt áttekinthetők legyenek. A beszámolóhoz készített összefoglaló EDA 1000 véletlenszerűen kiválasztott CSV fájl 1 176 164 sorából álló mintán készült, így az itt bemutatott eredmények több pálya és több mérkőzés közös mintázatait tükrözik.

Az EDA három fő kérdésre keresett választ:

1. Milyen szerkezetű az adathalmaz?
2. Mely jellemzők állnak a legerősebb kapcsolatban a kör végső kimenetelével?
3. A gránát- és pozíciójellegű változók mennyiben adnak kiegészítő információt az alapvető állapotjellemzők mellett?


A vizsgálatok alapján a célváltozó közel kiegyensúlyozott eloszlást mutatott, a terrorelhárító oldali győzelem aránya 48,7% volt, ez az 1. ábrán látható. A legerősebb korrelációk az állapot- és gazdasági különbségekhez kötődtek, ugyanakkor a gránátkészlethez kapcsolódó jellemzők is mérhető kapcsolatot mutattak a körkimenetelrel. A fázisonkénti összesítések alapján a középső szakaszban a gránátaktivitás és a friss sebzés hangsúlyosabb volt, míg a késői fázisban az emberelőny és a megmaradó felszerelés szerepe vált meghatározóbbá.

A kör kimenet szempontjából két különösen erős jellemző az élő játékosok számának különbsége és a felszerelésérték-különbség, ezért ezek együttes vizsgálatának eredménye látható a 2. ábrán.




1. ábra: A létszámfölény és a felszerelési előny együttes hatása a CT-oldal győzelmi esélyére

Ezek mellett a 3. ábrán látható, hogy akör különböző szakaszaiban mely jellemzők válnak hangsúlyosabbá.



2. ábra: A fő állapot- és gránátjellemzők fázisonkénti átlaga

A 4. ábra a célváltozóval legerősebben együtt mozgó húsz jellemzőt mutatja. Jól látható, hogy a legerősebb pozitív kapcsolatot főként a terrorelhárító oldal állapot- és felszerelésfölényét leíró változók adják, míg a negatív oldalon elsősorban a terrorista oldal erőforrásait és felszereltségét kifejező jellemzők jelennek meg.



3. ábra: A célváltozóval legerősebben korreláló 20 jellemző

2.3 Modellezés és kiértékelés

A projekt két fő modellezési irányra épült. Az első modell az Extreme Gradient Boosting (XGBoost) volt, amely egy döntési fákra épülő gradiensnöveléses eljárás, és különösen jól alkalmazható strukturált, táblázatos adatokon [3]. Ez a megközelítés stabil és erős kiindulási modellt adott a körkimenet becsléséhez, ezért alkalmas volt arra is, hogy referenciaként szolgáljon a gránát jellegű jellemzők hatásának vizsgálatához. A második modell a Long Short-Term Memory (LSTM) neurális hálózat volt, amely rekurzív felépítésének köszönhetően alkalmas időbeli összefüggések modellezésére [4]. Ez a megközelítés azért volt különösen releváns a jelen feladatban, mert nemcsak az aktuális játékállapot, hanem a közvetlenül megelőző események és állapotváltozások is fontos információt hordozhatnak a kör várható kimeneteléről.

2.3.0 Tanító-, validáló- és teszhalmazok kialakítása

A projekt egyik fontos módszertani döntése az volt, hogy az adatszétválasztás ne soronként, hanem meccsszinten történjen. Ugyanazon mérkőzés egymást követő pillanatképei rendkívül hasonlóak, ezért a soronkénti keverés mesterségesen túl kedvező eredményekhez vezethetne. A meccsszintű szétválasztás ezt a kockázatot jelentősen csökkentette.

További szempont volt, hogy a különböző pályák és versenykörnyezetek aránya a tanító és a tesztelő részhalmazokban ne torzuljon el túlzottan. Ennek megfelelően az adatkezelési folyamat úgy készült el, hogy a lehető leginkább megőrizze a mérkőzésanyag heterogenitását. A korai kísérletek gyorsabb futtatása érdekében kezdetben az adathalmaz 30%-os részmintája is használatban volt, a végső modellek azonban már a teljes, 100%-os adathalmazon kerültek kiértékelésre.

2.3.1 XGBoost

2.3.1.1 Modellezési folyamat

Az XGBoost választását az indokolta, hogy a bemenet alapvetően táblázatos, sokféle numerikus állapotjellemzőből álló adathalmaz volt, amelyre ez a módszer jól illeszkedik [3]. Az XGBoost emellett lehetőséget adott arra is, hogy a különböző jellemzőcsoportok hatása összehasonlítható módon legyen vizsgálható, ezért megfelelő alapmodellnek bizonyult a gránátjellegű változók értékeléséhez.

A modellezési folyamat során meccsszintű adatszétválasztás, korai leállítási, hiperparaméter-keresés és jellemzőblokkok szerinti összehasonlító futások készültek. A

hiperparaméter-vizsgálatok kezdetben elsősorban a modellkapacitást és a regularizáció mértékét befolyásoló beállításokra fókuszáltak. Ennek keretében változott többek között a fák maximális mélysége, a minimálisan szükséges levéltömeg, a gyermekcsomópontokra vonatkozó minimumfeltétel, a sor- és oszlopmintavételezés aránya, valamint az L2 regularizáció erőssége. A korai keresési szakaszban ezeknek a paramétereknek először inkább a nagyságrendi viselkedése került feltérképezésre, majd a kedvezőbb tartományokban célzottabb keresés történt.

A kezdeti kísérletek azt mutatták, hogy a túl nagy modellkapacitás gyorsan rontja az általánosítóképességet. Különösen a mélyebb fák és a gyengébb regularizáció mellett jelent meg erősebb túlilleszkedés, amikor a tanítóhalmazon javuló eredményekhez a validációs teljesítmény romlása társult. Ezért a későbbi futások a visszafogottabb, erősebben regularizált konfigurációk irányába mozdultak el, amelyek stabilabb validációs viselkedést és megbízhatóbb teszteredményeket adtak.

2.3.1.2 Eredmények

A végső összehasonlításban három XGBoost modellváltozat szerepelt: egy gránátjellemzők nélküli modell, egy teljes gránátkészletet használó modell, valamint egy olyan változat, amely a villantógránáthoz kapcsolódó jellemzőket elhagyta. A három modell teljesítménye nagyon közel alakult egymáshoz, ami arra utalt, hogy a gránátjellemzők globálisan nem hoznak nagy ugrást, ugyanakkor bizonyos lokális helyzetekben mégis hordozhatnak többletinformációt.

A harmadik, villantógránát nélküli változat bevezetését az indokolta, hogy a korábbi elemzések alapján a villanógránát jellegű oszlopok viselkedése zajosabbnak tűnt, mint a füst- vagy molotov jellegű jellemzőké. Módszertani szempontból ezért nem volt elegendő csupán a teljes gránát modellt a gránát nélküli változathoz hasonlítani, hanem külön azt is érdemes volt megvizsgálni, hogy mi történik akkor, ha a gránát jellemzők megmaradnak, de a feltételezetten legzajosabb alcsoport kikerül a bemenetből. Ez a harmadik modell tehát egy célzott ellenőrzés arra, hogy a gránátinformáción belül mely részek hordoznak tisztább és melyek bizonytalanabb jelet. A tanítás eredményeit az 1. táblázat foglalja össze.

Modell	Jellemzők (db)	Pontosság	Precision	Recall	F1	Logloss	ROC AUC
Gránát nélkül	412	76.26%	73.36%	81.98%	77.43%	0.450	86.04%
Gránátokkal (Villantógránát nélkül)	498	76.36%	73.36%	82.28%	77.57%	0.451	86.05%
Gránátokkal	531	76.27%	73.29%	82.20%	77.49%	0.451	86.05%

1. Táblázat: A különböző XGBoost modellek tanításainak eredményei különböző metrikák mentén vizsgálva.

A gránát-hatás azonban globális hatásokon kevésbé kimutatható. A megfigyelések szerint egyes gránát aktivitásokat vizsgálva csoportonként, illetve a gránát nélküli bizonytalanságánál mutatható ki releváns eredmény. A teljes gránát modell és a gránát nélküli modell közötti átlagos valószínűségkülönbség kicsi maradt, és az átlag logaritmikus veszteség javulás enyhén negatív volt. Ez azt mutatta, hogy a gránát hatás nem általános, minden helyzetben jelentkező javulásként jelent meg, hanem sokkal inkább szélsőséges helyzetekben és taktikai szituációkban hordozott plusz információt. A 2. táblázatban azok az esetek látszanak, ahol a gránát jellemzőket igen, de villanó gránátokat nem tanuló modell mást jósolt, mint a gránát nélküli különböző gránátaktivitás esetekben.

Aktív csoport	Gránát modell győzelmi aránya
Minden eset	52.66%
Aktív gránátok	52.89%
Sok gránát akció	52.97%
Gránát sebzés	51.92%
Aktív füst vagy molotov	53.36%
Elmúlt 5 másodperc gránát	51.95%
Villanógránát effekt	49.54%

2. Táblázat: A gránátjellemzőket tartalmazó modell kedvezőbb teljesítményének aránya különböző helyzettípusokban.

A bizonytalansági összesítés azt mutatta, hogy a gránát jellemzők leginkább azokban a helyzetekben tudtak pozitív szerepet játszani, ahol a gránát nélküli modell eleve közel volt a döntési határhoz. A villanógránát jellegű jellemzők ezzel szemben zajosabbnak bizonyultak: a villanógránát effekt csoportban a gránát győzelmi arány 50% alá esett, míg a füst- és molotov jellegű aktív gránát helyzetekben a gránát modell győzelmi aránya meghaladta az 53%-ot.

2.3.2 LSTM

2.3.2.1 Modellezési folyamat

Az időfüggő modell bevezetését az indokolta, hogy a Counter-Strike számos fontos jelensége időbeli láncolatként értelmezhető. Egy füst, majd egy villantás, azt követően egy helyzetnyerés vagy ölés együtt sokkal informatívabb lehet, mint bármelyik elem önmagában. Az LSTM ezért nem egyetlen pillanatképből, hanem rövid hosszúságú állapotsorozatból becsülte meg a körgyőzelmi valószínűséget [4].

2.3.2.2 Eredmények

A végleges LSTM modell a teljes jellemzőkészletet használta. A globális teszteredmények alapján a modell versenyképesnek bizonyult: pontosság és ROC AUC alapján enyhén meg is haladta a végső XGBoost változatokat, ugyanakkor a valószínűségkalibrációt jobban tükröző mutatókban nem hozott egyértelmű áttörést. Ez azt jelentette, hogy az LSTM alkalmas volt erős rangsorolásra, de az XGBoost továbbra is stabilabb, egyszerűbben értelmezhető alapmodell maradt. A tanítás eredményeit a 3. Táblázat foglalja össze.

Modell	Jellemzők (db)	Accuracy	Precision	Recall	F1	Logloss	ROC AUC
LSTM	531	76.70%	74.84%	79.99%	77.33%	0.459	86.18%

3. Táblázat: Az LSTM modell tanításainak eredményei különböző metrikák mentén vizsgálva.


Az LSTM egyik legfontosabb kiegészítő eredménye a lokális magyarázhatóság volt. A neurális hálózatok közvetlenül nehezebben értelmezhetők, ezért a projektben a magyarázat előállításuk lokális, egyszerűbb helyettesítő modellek segítségével történt.

Az LSTM egyik legfontosabb kiegészítő eredménye a lokális magyarázhatósági elemzés volt. Mivel az ilyen típusú neurális hálózatok működése közvetlenül nehezebben értelmezhető, a projektben lokális helyettesítő modell segítségével történt az egyes előrejelzések magyarázata. Ez a

megközelítés rokonságot mutat a Local Interpretable Model-Agnostic Explanations (LIME) szemléletével, amelynek alapgondolata, hogy egy összetett modell viselkedése egy adott megfigyelés közvetlen környezetében egy egyszerűbb, jól értelmezhető modellel közelíthető [5].

A gyakorlatban ez azt jelentette, hogy az egyes kiválasztott körök környezetében ridge regressziós lokális lineáris modellek közelítették az LSTM által becsült valószínűségmozgásokat. Ennek segítségével azonosíthatóvá vált, hogy egy adott körön belül mely változók járultak hozzá leginkább az előrejelzés elmozdulásához, és milyen irányban hatottak a becsült körkimenetelre. A módszer ezért nem globális modellszintű magyarázatot adott, hanem esetről esetre mutatta meg, hogy az adott helyzetben mely tényezők voltak meghatározóak.


A nagyobb, 1000 véletlen körre kiterjedő összesítés alapján a legerősebb magyarázó tényezők között jellemzően a friss harci eseményeket, az emberelőnyt, az életerőviszonyokat és más közvetlen állapotváltozásokat leíró jellemzők szerepeltek. Ugyanakkor a gránátjellegű jellemzőcsaládok is visszatérően megjelentek a fontos tényezők között, ami arra utal, hogy ezek a változók az időbeli modellezés keretében érdemi többletinformációt hordozhatnak. Különösen fontos megfigyelés volt, hogy a villantógránátokhoz kapcsolódó jellemzők az XGBoost-alapú összehasonlításokban inkább zajosabbnak tűntek, míg az LSTM lokális magyarázataiban gyakrabban jelentek meg releváns tényezőként. Ez arra utal, hogy a villantógránátok hatása elsősorban időbeli kontextusban ragadható meg jól.



4. ábra: LSTM – et magyarázó ridge regressionben leggyakrabban megjelenő jellemzőcsaládok gránát és gránát nélküli esetben

2.3.2.3 Lokális XGBoost-LSTM összehasonlítás

A további elemzés során az is vizsgálat tárgyát képezte, hogy az XGBoost és az LSTM modellek miként viselkednek egyedi körök szintjén. A lokális összehasonlítások azt mutatták, hogy az LSTM több esetben pontosabban követte a körön belüli valószínűségváltozásokat, különösen olyan szituációkban, ahol az események időbeli lefutása önmagában is fontos információt hordozott. Ez arra utalt, hogy az időfüggő modell előnye elsősorban nem globális szinten, hanem az egyes körök dinamikájának megragadásában jelent meg.



5. ábra: LSTM és XGBoost összevetése pillanatonkénti győzelmi valószínűségben

2.4 Összegzés

Az önálló laboratóriumi munka központi kérdése az volt, hogy Counter-Strike 2 körállapotokból milyen pontossággal becsülhető meg a terrorelhárító oldal győzelmi valószínűsége, és ebben milyen szerepet játszanak a gránáthasználathoz kapcsolódó jellemzők.

Az eredmények alapján a pillanatkép alapú XGBoost modell stabil és megbízható alapmegoldást adott. A körkimenetel becslésében a legerősebb globális jeleket továbbra is az állapot- és gazdasági különbségek adták, miközben a gránátjellemzők globális előnye kicsi maradt. A célzott vizsgálatok ugyanakkor azt mutatták, hogy bizonytalan vagy aktív gránát helyzetekben ezek a változók érdemi többletjelentést hordozhatnak. Az ablációs elemzések és azon helyzetek vizsgálata mikor a két modell mást jósol különösen jól alátámasztották.

Az időfüggő LSTM modell globális szinten nem szorította háttérbe egyértelműen az XGBoostot, de fontos többletet adott a projektnek. A lokális elemzések alapján a modell képes volt olyan időbeli mintázatokra reagálni, amelyek a körök belső dinamikájához jobban illeszkednek. Emiatt a két megközelítés nem egymás egyszerű helyettesítője, hanem két eltérő nézőpontot képvisel ugyanazon feladatra: az XGBoost erős és jól kontrollálható alapmodell, az LSTM pedig a dinamikus, lokális viselkedés értelmezésében mutatott előnyt.

Az eredmények alapján a gránát jellemzők összességében nem bizonyultak a legerősebb prediktív tényezőknél, vagyis a körkimenetel becslését elsődlegesen továbbra is az állapot- és gazdasági különbségek határozták meg. Ugyanakkor több célzott vizsgálat alapján a gránát jellemzők nem tekinthetők fölöslegesnek sem, mert bizonytalan vagy aktív taktikai helyzetekben hasznos, kontextusfüggő kiegészítő információt hordozhattak. A gránát jellemzők elemzések további fontos tanulsága volt, hogy nem minden gránát jellegű változó bizonyult azonos mértékben hasznosnak. A villanó jellegű jellemzők az XGBoost alapú összehasonlításokban zajosabbnak tűntek, míg a villanó nélküli gránát változat több összehasonlításban tisztább pozitív jelet adott. Ugyanakkor az LSTM lokális magyarázhatósági eredményei azt mutatták, hogy a villanógránát hatásokhoz kapcsolódó változók időbeli kontextusban gyakran fontos magyarázó tényezőként jelentek meg. Ez arra utalt, hogy a gránát hatás nem egységes, hanem erősen kontextusfüggő.

A fél éves munka így nemcsak működő előrejelző modellt eredményezett, hanem egy szakdolgozati szintű továbbfejlesztésekhez is használható elemzési keretet. Ilyen irány lehet a villanógránátok részletesebb vizsgálata, a hibrid modellek alkalmazása és a lokális magyarázatok játékszakai értelmezése.

3. Irodalom, és csatlakozó dokumentumok jegyzéke

- [1] Xenopoulos, P., Doraiswamy, H., Silva, C. T.: Valuing Player Actions in Counter-Strike: Global Offensive. IEEE Big Data, 2020. Elérhető: <https://arxiv.org/pdf/2011.01324>
- [2] Xenopoulos, P., et al.: Optimal Team Economic Decisions in Counter-Strike. 2021. Elérhető: <https://arxiv.org/pdf/2109.12990>
- [3] Chen, T., Guestrin, C.: XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 785–794, 2016. DOI: <https://doi.org/10.1145/2939672.2939785>
- [4] Hochreiter, S., Schmidhuber, J.: Long Short-Term Memory. Neural Computation, 9(8), 1735–1780, 1997. Elérhető: <https://dblp.org/rec/journals/neco/HochreiterS97>
- [5] Ribeiro, M. T., Singh, S., Guestrin, C.: “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016. DOI: <https://doi.org/10.1145/2939672.2939778>